

Ejercicios Corte 1

Tiffany Mendoza S.

2026-02-11

Contents

1	Ejercicio 1	5
	Incendios forestales	5
	Desarrollo	6
2	Ejercicio 2	11
	Eventos deportivos	11
3	Ejercicio 3	17
	Población US	17

Chapter 1

Ejercicio 1

A partir del dataset `df`, el cual trata de los incendios forestales, realice las siguientes tareas:

- Filtrar los registros para incluir únicamente los incendios ocurridos en el estado de Idaho.
- Seleccionar únicamente las columnas `YEAR__`, `CAUSE` y `TOTALACRES`.
- Renombrar estas columnas con nombres más claros y descriptivos.
- Agrupar la información por `CAUSE` y `YEAR__`.
- Resumir el total de acres quemados para cada combinación de causa y año.
- Elaborar una visualización que muestre los resultados de manera clara.

Incendios forestales

```
library(tidyverse)
library(kableExtra)
library(ggplot2)
df <- read_csv('/Users/pctm/Library/Mobile Documents/com~apple~CloudDocs/RDataSets/StudyArea.csv')
```

Desarrollo

Filtrar los registros para incluir únicamente los incendios ocurridos en el estado de Idaho. Seleccionar y renombrar únicamente las columnas YEAR_, CAUSE y TOTALACRES.

```
df %>%
  filter(STATE == 'Idaho') %>%
  select(STARTYR=YEAR_, NATURE=CAUSE, ACRES=TOTALACRES) -> df_filtrado

head(df_filtrado)
```

```
## # A tibble: 6 x 3
##   STARTYR NATURE ACRES
##   <dbl> <chr>   <dbl>
## 1   1987 Human     5
## 2   1991 Natural  150
## 3   1991 Human   800
## 4   1990 Natural    2
## 5   1985 Human   38
## 6   1988 Human    2
```

Agrupar la informacion por cause y year.

```
df_filtrado %>%
  group_by(NATURE, STARTYR) %>%
  summarise(median_acres = mean(ACRES),
            ds_acres = sd(ACRES),
            mediana_acres = median(ACRES),
            RIC_acres = IQR(ACRES),
            min_acres = min(ACRES),
            max_acres = max(ACRES),
            q1_acres = quantile(ACRES)[2],
            q3_acres = quantile(ACRES)[4],
            total_acres = sum(ACRES)

            )-> showdf


kable(showdf, caption = "Agrupación por causa y año") %>%
  column_spec(2, width = "20em") %>%
  scroll_box(width = "100%", height = "550px")
```

Table 1.1: Agrupación por causa y año


NATURE	STARTYR	median_acres	ds_acres	mediana_acres
Human	1980	517.803597	1.694831e+03	6.00
Human	1981	933.457021	3.825587e+03	15.00
Human	1982	250.119118	6.722048e+02	7.50
Human	1983	339.735915	1.253732e+03	10.50
Human	1984	265.020144	7.082504e+02	10.00
Human	1985	407.397006	1.693777e+03	5.00
Human	1986	118.955647	5.148097e+02	0.30
Human	1987	93.178780	4.347462e+02	0.20
Human	1988	2383.539118	2.774656e+04	0.50
Human	1989	69.705473	5.974787e+02	0.10
Human	1990	383.117472	4.414106e+03	0.20
Human	1991	64.117042	3.265620e+02	0.10
Human	1992	546.999486	9.005925e+03	0.10
Human	1993	15.759004	1.760988e+02	0.10
Human	1994	202.060391	2.569693e+03	0.10
Human	1995	344.379412	1.736445e+03	3.00
Human	1996	432.732964	2.337182e+03	1.00
Human	1997	56.452976	1.954490e+02	1.00
Human	1998	140.686829	9.511555e+02	0.20
Human	1999	145.764691	9.246913e+02	0.80
Human	2000	304.265734	2.047859e+03	0.45
Human	2001	111.183656	6.343607e+02	0.50
Human	2002	27.298084	1.586931e+02	0.20
Human	2003	297.619109	1.791910e+03	0.50
Human	2004	25.623855	1.027188e+02	0.20
Human	2005	521.418211	3.291711e+03	0.70
Human	2006	533.620596	4.188152e+03	1.00
Human	2007	350.372889	2.628756e+03	1.00
Human	2008	110.406074	6.708337e+02	0.10
Human	2009	32.274474	2.292115e+02	0.10
Human	2010	370.867795	5.504310e+03	0.20
Human	2011	63.656599	7.767369e+02	0.30
Human	2012	725.719412	8.608011e+03	2.00
Human	2013	162.263402	1.463046e+03	0.40
Human	2014	34.166866	3.258851e+02	0.20
Human	2015	141.618155	9.176076e+02	0.25
Human	2016	841.810517	1.236872e+04	0.10
Natural	1980	523.636585	1.715754e+03	0.55
Natural	1981	1947.840141	7.226118e+03	5.00
Natural	1982	409.290291	1.652043e+03	1.00
Natural	1983	1423.292308	3.983337e+03	25.00
Natural	1984	1065.236719	4.133776e+03	2.00
Natural	1985	1337.591139	3.898585e+03	3.00
Natural	1986	416.578816	3.031769e+03	0.20
Natural	1987	298.436397	2.879928e+03	0.10
Natural	1988	926.488095	1.487055e+04	0.20
Natural	1989	130.236686	1.169256e+03	0.20
Natural	1990	37.968415	4.095728e+02	0.10
Natural	1991	84.077487	5.903141e+02	0.10
Natural	1992	456.596849	5.625640e+03	0.10
Natural	1993	4.603684	3.832958e+01	0.10

Gráficos

```
ggplot(showdf, aes(x = factor(STARTYR), y = total_acres, fill = NATURE)) +
  geom_col() +
  labs(x="Año", y="Total acres", title="Total anual por causa") +
  theme_minimal() +
  scale_y_continuous(labels = scales::comma) +
  theme(axis.text.x = element_text(angle=45, hjust=1))
```



El gráfico de barras muestra que la variación anual en acres quemados es muy alta y está dominada por unos pocos años con incendios extremadamente grandes; en esos picos la mayor parte del área quemada corresponde a causas naturales, mientras que las causas humanas contribuyen de forma constante pero en magnitud mucho menor.



Este gráfico muestra, año a año, la distribución del tamaño de incendios (acres por incendio) mediante boxplots: la caja (IQR) marca la dispersión central, la línea roja indica la mediana, los bigotes extienden la variación típica y los puntos/extremos fuera de los bigotes son outliers / mega-fires. Visualmente se aprecia que en la mayoría de los años la mediana es baja (los puntos rojos están cerca de la base), mientras que los bigotes y los outliers alcanzan valores enormes en unos pocos años. Esto indica una distribución con cola larga a la derecha: muchos incendios pequeños y unos pocos incendios extremadamente grandes que empujan la escala.

Chapter 2

Ejercicio 2

Trabajaremos con el conjunto de datos de 120 años de historia olímpica adquirido por Randi Griffin en Randi-Griffin y puesto a disposición en `athlete_events`. Su tarea consiste en identificar los cinco deportes más importantes según el mayor número de medallas otorgadas en el año 2016, y luego realizar el siguiente análisis:

- Genere una tabla que indique el número de medallas concedidas en cada uno de los cinco principales deportes en 2016.
- Elabore una tabla que muestre la distribución de la edad de los ganadores de medallas en los cinco principales deportes en 2016.
- Identifique qué equipos nacionales ganaron el mayor número de medallas en los cinco principales deportes en 2016.
- Presente un resumen de la tendencia del peso de los atletas masculinos y femeninos ganadores en los cinco principales deportes en 2016.

Eventos deportivos

```
library(tidyverse)
library(kableExtra)
library(ggplot2)
df <- read_csv('/Users/pctm/Desktop/Universidad/Sem 6/athlete_events.csv')
```

Table 2.1: Numero de medallas por deporte en 2016

Sport	medal_count
Athletics	192
Swimming	191
Rowing	144
Football	106
Hockey	99

Número de medallas concedidas en cada uno de los cinco principales deportes en 2016

```
df %>%
  filter(Year == 2016, !is.na(Medal)) %>%
  count(Sport, name = "medal_count") %>%
  arrange(desc(medal_count)) %>%
  slice_head(n = 5) -> top5

kable(top5, caption = "Numero de medallas por deporte en 2016")

top5_sports <- c("Athletics", "Swimming", "Rowing", "Football", "Hockey")
df_filtrado <- df %>%
  filter(Year == 2016, Sport %in% top5_sports, !is.na(Medal)) %>%
  select(Sport, Name, Age, Sex, Team, Medal, Weight)
```

Distribución de la edad de los ganadores de medallas en los cinco principales deportes en 2016.

```
df_filtrado %>%
  group_by(Sport) %>%
  summarise(
    n = n(),
    mean_age = mean(Age, na.rm = TRUE),
    median_age = median(Age, na.rm = TRUE),
    sd_age = sd(Age, na.rm = TRUE),
    IQR_age = IQR(Age, na.rm = TRUE),
    min_age = min(Age, na.rm = TRUE),
    max_age = max(Age, na.rm = TRUE),
    .groups = "drop"
  ) %>%
```

Table 2.2: Tabla de distribución de edad

Sport	n	mean_age	median_age	sd_age	IQR_age	min_age	max_age
Athletics	192	26.41146	26	4.131665	5.25	19	40
Swimming	191	23.23037	22	4.013047	4.00	16	36
Rowing	144	28.12500	28	3.871855	6.00	20	40
Football	106	24.08491	23	4.336156	6.00	17	34
Hockey	99	26.38384	27	4.072574	5.00	19	37

Table 2.3: Top 5 equipos

Team	medal_count
United States	127
Germany	88
Great Britain	69
Canada	45
Australia	43

```

arrange(desc(n)) -> dist_edad

kable(dist_edad, caption = "Tabla de distribución de edad")

```

Equipos nacionales ganaron el mayor número de medallas en los cinco principales deportes en 2016.

```

df_filtrado %>%
  group_by(Team) %>%
  count(Team, name = "medal_count") %>%
  arrange(desc(medal_count)) %>%
  head(n=5) -> top5_teams

kable(top5_teams, caption = "Top 5 equipos")

```


Tendencia del peso de los atletas masculinos y femeninos en los cinco principales deportes en 2016.

```
df_filtrado %>%
  group_by(Sex) %>%
  summarise(
    mean_w = mean(Weight, na.rm = TRUE),
    median_w = median(Weight, na.rm = TRUE),
    min_w = min(Weight, na.rm = TRUE),
    max_w = max(Weight, na.rm = TRUE),
    sd_w = sd(Weight, na.rm = TRUE),
    IQR_w = IQR(Weight, na.rm = TRUE)) -> tendencia_w

kable(tendencia_w)
```

Sex	mean_w	median_w	min_w	max_w	sd_w	IQR_w
F	65.24507	65	40	136	10.04168	12
M	81.80914	80	47	134	12.97826	17

```
ggplot(df_filtrado, aes(x = factor(Sex), y = Weight, fill = Sex)) +
  geom_boxplot(outlier.shape = 21, alpha = 0.6) +
  geom_jitter(width = 0.12, alpha = 0.5, size = 1, color = "black") +
  stat_summary(fun = mean, geom = "point", shape = 23, size = 3, fill = "white") +
  labs(title = "Distribución del peso por sexo",
       x = "Sexo",
       y = "Peso (kg)") +
  theme_minimal() +
  theme(legend.position = "none")
```



Para F (mujeres): la mediana está alrededor de 65 kg y la caja (IQR) es relativamente estrecha, lo que indica que la mayoría de las atletas ganadoras se agrupan cerca de ese valor; los bigotes son moderados y aparecen pocos outliers, aunque hay una cola derecha leve con algunos pesos atípicos. Para M (hombres): la mediana se ubica aproximadamente entre 75–80 kg, la caja es más ancha (mayor IQR) señalando mayor dispersión interna, y los bigotes junto con numerosos puntos atípicos muestran una cola derecha más pronunciada —es decir, hay más observaciones con pesos extremos. En ambos grupos se observan valores atípicos que podrían deberse a posiciones/disciplinas específicas.

Chapter 3

Ejercicio 3

Considere el conjunto de datos `us_state_population.tsv` ubicado en la carpeta de datos de Python de github. Repita el procedimiento planteado en cada ítem de esta sección para obtener el nuevo dataframe con las nuevas columnas `Year` y `Population`. Realice unión y separación utilizando las columnas `State` y `Code`.

Población US

```
library(tidyverse)
library(kableExtra)
library(ggplot2)
df <- read_tsv('/Users/pctm/Desktop/Universidad/Sem 6/us_state_population.tsv')
```

Recopilación

```
head(df)
```

```
## # A tibble: 6 x 11
##   State      Code `2010` `2011` `2012` `2013` `2014` `2015` `2016` `2017` `2018`
##   <chr>    <chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Alabama  AL    4.79e6 4.80e6 4.82e6 4.83e6 4.84e6 4.85e6 4.86e6 4.88e6 4.89e6
## 2 Alaska   AK    7.14e5 7.22e5 7.30e5 7.37e5 7.36e5 7.38e5 7.42e5 7.40e5 7.37e5
## 3 Arizona  AZ    6.41e6 6.47e6 6.56e6 6.63e6 6.73e6 6.83e6 6.95e6 7.05e6 7.17e6
## 4 Arkansas AR    2.92e6 2.94e6 2.95e6 2.96e6 2.97e6 2.98e6 2.99e6 3.00e6 3.01e6
## 5 Californ~ CA    3.73e7 3.76e7 3.80e7 3.83e7 3.86e7 3.90e7 3.92e7 3.94e7 3.96e7
## 6 Colorado CO    5.05e6 5.12e6 5.19e6 5.27e6 5.35e6 5.45e6 5.54e6 5.62e6 5.70e6
```

```
names(df)
```

```
## [1] "State" "Code" "2010" "2011" "2012" "2013" "2014" "2015" "2016"
## [10] "2017" "2018"
```

```
gather(df, '2010':'2018',
        key="YEAR",
        value="POPULATION") -> df_reco
```

```
df_reco
```

```
## # A tibble: 459 x 4
##   State      Code YEAR POPULATION
##   <chr>      <chr> <chr>      <dbl>
## 1 Alabama    AL    2010    4785448
## 2 Alaska     AK    2010     713906
## 3 Arizona    AZ    2010    6407774
## 4 Arkansas   AR    2010    2921978
## 5 California CA    2010    37320903
## 6 Colorado   CO    2010     5048281
## 7 Connecticut CT    2010     3579125
## 8 Delaware   DE    2010      899595
## 9 District of Columbia DC    2010      605085
## 10 Florida    FL    2010    18845785
## # i 449 more rows
```

Unión

```
unite(df_reco, State_Code, State, Code) -> unite_tb
unite_tb
```

```
## # A tibble: 459 x 3
##   State_Code      YEAR POPULATION
##   <chr>      <chr>      <dbl>
## 1 Alabama_AL    2010    4785448
## 2 Alaska_AK     2010     713906
## 3 Arizona_AZ     2010    6407774
## 4 Arkansas_AR    2010    2921978
## 5 California_CA  2010    37320903
## 6 Colorado_CO    2010     5048281
## 7 Connecticut_CT 2010     3579125
## 8 Delaware_DE    2010      899595
```

```
## 9 District of Columbia_DC 2010      605085
## 10 Florida_FL              2010      18845785
## # i 449 more rows
```

Separación

```
separate(unite_tb, "State_Code", into = c("State", "Code")) -> separate_tb
```

```
## Warning: Expected 2 pieces. Additional pieces discarded in 99 rows [9, 30, 31, 32, 33,
## 34, 35, 40, 41, 42, 49, 60, 81, 82, 83, 84, 85, 86, 91, 92, ...].
```

```
separate_tb
```

```
## # A tibble: 459 x 4
##   State      Code YEAR POPULATION
##   <chr>      <chr> <chr>      <dbl>
## 1 Alabama    AL    2010      4785448
## 2 Alaska     AK    2010       713906
## 3 Arizona    AZ    2010      6407774
## 4 Arkansas   AR    2010      2921978
## 5 California CA    2010      37320903
## 6 Colorado   CO    2010       5048281
## 7 Connecticut CT    2010       3579125
## 8 Delaware   DE    2010       899595
## 9 District   of    2010       605085
## 10 Florida   FL    2010      18845785
## # i 449 more rows
```